

ALCANCE DEL TFM

ENTREGAS

ENTREGA 1: Análisis de datos, perfilado y diseño de modelo de datos.

Esta primera entrega nos sirve para comprender y analizar los datos que disponemos de manera que entendamos mejor qué significan nuestros datos, su calidad, su relación con términos de negocio, cómo están relacionados los datos entre sí, etc..

DICCIONARIO DE DATOS

- A raíz de los datos de los que se parte para el TFM se debe crear un Diccionario de Datos, en Excel.

El diccionario de datos contiene el análisis detallado de los datasets que vamos a utilizar para el desarrollo del TFM así como analizar el comportamiento de los registros de que contienen los datasets. Debe contener la descripción de cada dataset, el número de filas y columnas que contienen, el detalle de la información relacionada y el potencial que se destaca en cada uno.

PERFILADO DE DATOS

- Realizar un Perfilado de datos. Se debe utilizar Python con las librerías de perfilado necesarias. Se debe crear un Notebook para que esté documentado el código.


El perfilado nos muestra las estadísticas de los diferentes campos del conjunto de datos y podemos consultar tanto la cantidad de registros nulos, no nulos, las medias, los valores mínimos y máximos de cada atributo.

Debe darse también una pequeña opinión de estos perfilados, realizar un análisis de los resultados. También basados en el siguiente punto para hacer un análisis más detallado.

ANALISIS DE LOS DATOS

- Una vez hechos los dos pasos anteriores se tratar de realizar una comprensión de los datos realizando un análisis de los mismos para entenderlos mejor. También se haría en Python donde se mostrarían gráficas por ejemplo de la distribución de un valor para poder explicarlo mejor.

Ejemplo, distribución del precio de la vivienda en un barrio en concreto, marcando como elevados los que superan la media.



CALIDAD DEL DATO


- Realizar Calidad del dato. Se debe analizar la calidad del dato que tenemos, además definir e implementar las reglas de calidad que velarán porque nuestros datos tengan la mejor calidad. Todo esto también se desarrolla en Python.

Ejemplo: regla que valida el número de registros que tienen el campo Teléfono del Cliente a NULO. Regla que valida el número de registros que tienen el campo Teléfono del Cliente con un formato incorrecto.

MODELO DE DATOS

- Definir el modelo de datos que albergan nuestros datasets de partida del TFM. Este modelado de datos consiste en identificar los datasets como tablas e identificar las claves primarias, las claves foráneas y si existen relaciones entre tablas. Se debe implementar en MySQL, de modo que los datasets estén cargados en tablas a las que iremos identificando lo anterior.

Ejemplo: este es un diagrama entidad relación donde se ponen las tablas que se utilizan, qué campo es la Primary Key, qué campos son las Foreign Key y qué tablas se relacionan entre sí.



- Entregables para esta primera entrega:

- Notebook con los procesos hechos en Python: procesos que tienen el perfilado el análisis y la calidad del dato. Siendo un notebook debe estar bien explicado cada punto ya que este será el documento.
- Fichero Excel con el diccionario de datos.
- Modelo de datos generado con MySQL en formato Word o PDF o en imagen pero que se vea claro.

¿Qué se va a evaluar?

- Que exista un perfilado de datos donde se pueda ver los registros que hay, los duplicados, los valores nulos, valores atípicos, etc.. de cada columna/atributo.
- Que se definan reglas de calidad del dato que sean coherentes con los datos que se han analizado
- Que se haya hecho un análisis de los datos con conclusiones.
- Que se entregue un diccionario de datos donde venga definida cada columna/atributo sabiendo qué significa, de qué tipo es y si tiene valores atípicos o reglas de calidad que deben vigilar su valor.
- Que se entregue un modelo de datos donde esté definida de manera correcta:
 - o Identificadas correctamente las primary keys.
 - o Identificadas correctamente las foreign keys.
 - o Bien relacionadas las tablas.

ENTREGA 2:

El objetivo de esta entrega es profundizar con nuestros datos de manera que utilizando ya las técnicas de ETL seamos capaces de transformar y cargar los datos obteniendo KPIs y/o nuevas tablas que nos permitan explotar mejor la información.

Se va a pedir para esta entrega realizar los siguientes puntos:

INGESTAR LOS DATOS

- Las tablas que hemos creado en el proceso anterior mediante MySQL deben ser alimentadas con los datos de los datasets. Para ello hay que crear procesos en Python que limpien y preparen esos datasets para poder insertar los datos en las tablas de MySQL.

TRANSFORMACIÓN DE LOS DATOS

- Realizar procesos en Python que integren los datos, que transformen datos y que carguen datos. Las transformaciones pueden ser de muchos tipos, pero hay que implementar varias. La carga tiene que realizarse a tabla de MySQL, no hablamos de la primera parte que carga los ficheros a tablas, sino que si se han realizado transformaciones, juntado tablas, realizado algún cálculo... todo ello estará guardado en una nueva tabla.

MODELO DE DATOS DATAWAREHOUSE(OPCIONAL)

- Definición del modelo de datos del Datawarehouse Informacional. Si en el punto anterior han surgido nuevas tablas para almacenar los datos transformados y/o calculados, se debe realizar el modelo de datos de estas nuevas tablas. Esto implica identificar en esas tablas cuál es la Primary Key, cuáles las Foreign Key e indicar cómo se relacionan.

KPIs

- Definición e implementación de los KPIs que deseamos tener en el TFM. En este punto del TFM debemos ser ya capaces de saber qué cosas vamos a querer medir. Ejemplo: número medio de llamadas atendidas por el Contact Center cada semana.

- Entregables para esta segunda entrega:

- Todo lo que sea de Python irá en el mismo Notebook que la entrega 1
- Si hay nuevo modelo de datos para el DWH se hará también con MySQL de la misma manera que la Entrega 1.
- La definición de los KPIs irá a un documento Word, explicando cada uno de ellos.
- El cálculo de los KPIs debe ir en el Notebook, bien explicado.
Recomendación: crear una tabla donde se guarde definición de los KPIs y los resultados obtenidos en cada ejecución.

¿Qué se va a evaluar?

- Que se han ingestado los ficheros o conjuntos de datos en tablas de MySQL

- Que se han realizado transformaciones con los datos mediante Python, cuantas más transformaciones (que tengan sentido) mejor será la evaluación de esta parte
- Que se han creado KPIs mediante Python siendo capaces de almacenar el resultado de sus ejecuciones en tabla.
- Si se han creado nuevas tablas para el datawarehouse será evaluado como un plus. Este tipo de tablas pueden ser por ejemplo tablas agregadas, tablas que unen varias tablas, etc... siempre de cara a la explotación de datos.

ENTREGA 3:

Esta entrega es la última parcial, es en la que se debe realizar la explotación de los datos mediante herramientas visuales del tipo PowerBI.

- Para la explotación de los datos se debe crear una visualización en la herramienta PowerBI. Esta visualización tiene que tener un buen diseño y debe tener suficientes KPIs que aporten valor. Hay que pensar que si lo que se está entregando se puede hacer con un Excel con filtros es que no es suficiente. Por lo que hay que explotar todas las bondades que tiene PowerBI de cara a hacer una buena visualización.

- Describir los insights encontrados. A raíz de la visualización tiene que poder realizarse un análisis exploratorio que nos permita descubrir algún insight. Se debe documentar cómo se ha llegado a encontrar dicho insight.

OPCIONAL

A parte de la visualización, se puede usar técnicas de analítica avanzada y usar algoritmos que muestren por ejemplo correlación entre variables, de manera que se puedan descubrir esos insights. Esta parte sería opcional para el grupo que se anime a intentarlo.

- También de manera opcional se puede hacer machine learning usando lo aprendido en el Máster. Se puede hacer con Python o con BIGML

- Entregables:

- Fichero PowerBI.
- Documento Word donde expliquen los insights, o Notebook si han hecho analítica avanzada en la parte opcional.

- ¿Qué se evalúa?

- Diseño atractivo, buen uso de los colores, del orden, que tenga un menú principal, con imágenes y fondos que lo hagan más sencillo de usar.
- Capacidad de explotación, que con el PowerBI el usuario pueda explorar y analizar con el máximo detalle los datos de su empresa.
- Generación de insights, que el PowerBI permita descubrir insights.

Memoria y Defensa

Una vez hechas las anteriores entregas llegará el momento de la Memoria y la Defensa. Todo viene explicado en la guía del TFM, pero como resumen:

- La nota del TFM es 80% nota de esa memoria y 20% nota de la Defensa.
- La nota de la memoria la pone el tutor.
- La nota de la defensa se pacta entre los tutores que acudan a la defensa.

Es muy recomendable entregar también el powerpoint de la defensa en la ENTREGA FINAL para que el tutor os ayude en que quede bien.



inesdi

Digital Business School

Madrid
Barcelona
Online

► **Campus Madrid**

Velázquez, 57 08001 Madrid
+34 91 290 33 58

► **Campus Barcelona**

Mallorca, 27 08029 Barcelona
+34 93 227 81 50

► **Campus Online**

Desde cualquier lugar del mundo

 Inesdi

 @InstitutoInesdi

 @inesdi_dbs

 Inesdi Digital Business School

 Inesdi Digital Business School