

Entrega 1 TFM-Actualizada

Análisis de Datos Bancarios - Banco Sabadell

Estudiantes:

Jannyn Mendoza

Juan Mateo Duque

Nicole Custode

María Isabel Sanguino

Sacha Aponte

INSTITUCIÓN: INESDI - Máster Business Analytics e IA

FECHA: 21 de July de 2026

DESCRIPCIÓN DEL PROYECTO

PROYECTO:

Segmentación predictiva y diseño de estrategias de inversión temprana para clientes bancarios del sector español mediante el uso de Business Analytics e Inteligencia Artificial

OBJETIVOS DEL PROYECTO:

1. Segmentar clientes según el tipo de cuenta que posee y analizar el comportamiento financiero, identificar cual es el tipo de cuenta con mayor y menor cantidad de clientes y analizar el porqué.
2. Construir un modelo enfocado en el tipo de cliente según su perfil, sus necesidades y el tipo de consumo al que debe incurrir para acceder a la siguiente categoría/tarjeta
3. Diseño de un modelo analítico para los jóvenes con el fin de potenciar las estrategias de inversión basado en sugerencias automatizadas

METODOLOGÍA:

Este proyecto utiliza técnicas avanzadas de análisis de datos, machine learning y business intelligence para analizar datos bancarios históricos, identificar patrones de comportamiento y desarrollar modelos predictivos para la segmentación de clientes y diseño de estrategias de inversión.

DICCIONARIO DE DATOS:

Referencia: Revisar el archivo excel: Diccionario_Actualizado.xlsx

MODELO DE DATOS:

Referencia: Revisar el archivo pdf: MER.pdf

PERFILADO DE DATOS:

Referencia: Revisar el archivo EntregaNoteboookTFM_.ipynb

CELDA 1: CÓDIGO

```
#Inicio importando las librerias que necesito
import pandas as pd
import numpy as np
import matplotlib as plt
import matplotlib.pyplot as plt
from pathlib import Path
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go
import plotly.io as pio
import plotly.express as px
import plotly.graph_objects as go
from plotly.subplots import make_subplots

from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import classification_report, roc_auc_score, confusion_matrix,
ConfusionMatrixDisplay

pd.set_option('display.max_columns', 100)
pd.set_option('display.width', 200)
RANDOM_STATE = 42
print(f"Librerias importadas OK ■")
```

RESULTADOS:

```
Librerias importadas OK ■
```

CELDA 2: CÓDIGO

```
#Carga del dataset de Sabadell en Python, se agrego la libreria
##from pathlib import Path para que suba sin necesidad de colocar el directorio
# en el df_datosabadell se demora uno aproximadamente 4 seg porque es de 10000 registros la BD
input_dir = Path.cwd() / "input"
xlsx_files = []
if input_dir.exists():
    xlsx_files = sorted(input_dir.glob("*.xlsx"))
else:
    xlsx_files = sorted(Path.cwd().glob("*.xlsx"))

if not xlsx_files:
    raise FileNotFoundError(
        f"No se encontró ningún archivo .xlsx en {input_dir} ni en el directorio actual."
    )

excel_path = xlsx_files[0]
df_datosabadell = pd.read_excel(excel_path, engine="openpyxl")
print(f"Listo■! Excel cargado desde: {excel_path}")
print(f"output_dir será: {Path.cwd() / 'output'}")
```

RESULTADOS:

```
Listo■! Excel cargado desde: c:\Users\jmendoza\OneDrive - Getronics\Escritorio\INESDI\TFM\Entrega 1 -TFM Ethos\BD_Sabadell.xlsx
output_dir será: c:\Users\jmendoza\OneDrive - Getronics\Escritorio\INESDI\TFM\Entrega 1 -TFM Ethos\output
```

CELDA 3: CÓDIGO

```
# Estadística descriptiva de las variables clave de perfil / consumo
vars_clave = ['antig', 'edad', 'totalpasta', 'renta_final', 'gastos_tot', 'nivren',
              'margecomercialut', 'credit', 'revolving', 'tothipo', 'nominaimp', 'rdom', 'tpv']
df_datosabadell[vars_clave].describe().T
```

RESULTADOS:

	count	mean	std	min	25%	50%	75%	max
antig	10000.0	218.333500	795.911927	1.00	47.000000	121.000	233.000000	9999.00
edad	10000.0	49.354400	20.248531	0.00	36.000000	49.000	64.000000	116.00
totalpasta	10000.0	23847.890669	86505.052000	0.00	287.467500	2123.225	17078.425000	4798534.49
renta_final	7239.0	25369.533403	81677.699690	4367.76	12310.628077	16479.540	25385.683636	4496606.59
nivren	10000.0	1.933000	0.937869	0.00	1.000000	2.000	3.000000	5.00
margecomercialut	10000.0	128.151498	462.907653	-1961.80	6.077500	36.050	138.195000	31639.73
credit	10000.0	100.536738	2457.438350	0.00	0.000000	0.000	0.000000	134200.66
revolving	10000.0	53.858220	332.113919	0.00	0.000000	...		

CELDA 4: CÓDIGO

```
#Función para contar la cantidad total de clientes en la BD
total_clientes=df_datosabadell.id_cliente.count()
print(f"El total de clientes registrados en la BD es : {total_clientes}")
```

RESULTADOS:

```
El total de clientes registrados en la BD es : 10000
```

CELDA 5: CÓDIGO

```
#Perfilados estadísticos de los diferentes campos, se muestran valores
#mínimos y máximos.
# Análisis:
# Edad =0.000000 corresponde a padres que crean una cuenta de ahorro para sus hijos
# totalpasta =0.000000 corresponde a los cliente que no tiene fondos.
# impoped = 0.000000 corresponde a los clientes que no tuvieron egresos en su cuenta
resumen = df_datosabadell.describe()
print(resumen)
```

RESULTADOS:

	id_cliente	antig	edad	totalpasta	impoped	impopeh	ind_cuentaexpansion	ind_cuentaexpansionne
count	10000.00000	10000.000000	10000.000000	1.000000e+04	1.000000e+04	1.000000e+04	10000.000000	10000.000000
mean	5000.50000	218.333500	49.354400	2.384789e+04	4.945997e+03	5.433100e+03	0.347200	0.347200
std	2886.89568	795.911927	20.248531	8.650505e+04	2.296940e+04	2.168653e+04	0.476104	0.476104
min	1.00000	1.000000	0.000000	0.000000e+00	0.000000e+00	0.000000e+00	0.000000	0.000000
25%	2500.75000	47.000000	...					

Del análisis de la base de datos se desprende que:

-El 49.7% de los nulos representa un volumen de 4.966 registros. Resulta relevante señalar que un conjunto de variables clave (jubilados, entre18_45, entre46_65, tipofamilia, menores18 y miembrosfamilia) comparte de forma idéntica esta cifra de omisiones. Este patrón confirma que la inconsistencia se origina en la fuente de datos primaria, reflejando una falta sistemática de información demográfica para casi la mitad de los clientes en lugar de ausencias aisladas. Por consiguiente, con el fin de preservar la integridad del análisis, se optó por definir una nueva categoría explícita que agrupe estas observaciones.

-renta_final (27.6% nulos), los valores nulos está ligado a un patrón real: los clientes sin renta_final son más jóvenes (41.9 vs 52.2 años) y con menor vinculación (0.24 vs 0.42). Es decir, la ausencia del dato es en sí misma informativa (probablemente clientes jóvenes/nuevos sin cruce fiscal). Por eso no se elimina la columna, se imputa por grupo (nivren, que solo correlaciona 0.09 con renta_final, así que no es redundante) y se añade un flag de "sin dato" para no perder esa

señal.

CELDA 6: CÓDIGO

```
# Panorama general: tipos de dato y nulos
resumen = pd.DataFrame({
    'dtype': df_datosabadell.dtypes,
    'nulos': df_datosabadell.isna().sum(),
    '%_nulos': (df_datosabadell.isna().mean()*100).round(1)
}).sort_values('%_nulos', ascending=False)
resumen.head(20)
```

RESULTADOS:

	dtype	nulos	%_nulos
jubilados	float64	4966	49.7
entre18_45	float64	4966	49.7
entre46_65	float64	4966	49.7
tipofamilia	str	4966	49.7
menores18	float64	4966	49.7
miembrosfamilia	float64	4966	49.7
renta_final	float64	2761	27.6
sio_mediospago	float64	114	1.1
sio_transaccionalidad	float64	114	1.1
sio_ahorro	float64	114	1.1
sio_accionabilidad	float64	114	1.1
sio_aldia	float64	114	1.1
sio_financiacion	float64	114	1.1
sio_desvinculacion	float64	114	1.1
sio_captacion	float64	114	1.1
sio_vinculacion	float64	114	1.1
sio_noaccionable	float64	114	1.1
fase	float64	114	1.1
sio_proteccion	float64	114	1.1
ind_cvprestige	int64	0	...

CELDA 7: CÓDIGO

```
#El Resto de los campos sio_* y 'fase' corresponde al 1.1% nulos, 114 filas,
# se toma la decisión de imputar con la mediana (robusta frente a outliers, más segura
# que la media en variables con colas largas) es preferible a perder 114
# registros completos de la muestra.
cols_sio_imputar = [
    'sio_vinculacion', 'sio_desvinculacion', 'sio_ahorro', 'sio_aldia',
    'sio_captacion', 'sio_financiacion', 'sio_mediospago',
    'sio_transaccionalidad', 'sio_proteccion', 'sio_noaccionable', 'sio_accionabilidad'
]
for c in cols_sio_imputar:
    df_datosabadell[c] = df_datosabadell[c].fillna(df_datosabadell[c].median())

df_datosabadell['fase'] = df_datosabadell['fase'].fillna(df_datosabadell['fase'].median())
```

CELDA 8: CÓDIGO

```
nulos_restantes = df_datosabadell.isna().sum()
nulos_restantes = nulos_restantes[nulos_restantes > 0]

print(f"\nFilas finales: {len(df_datosabadell)} | Columnas finales: {df_datosabadell.shape[1]}")
if nulos_restantes.empty:
    print("■ No quedan valores nulos en el dataset.")
else:
    print("■■ Columnas con nulos restantes:")
    print(nulos_restantes)
```

RESULTADOS:

```
Filas finales: 10000 | Columnas finales: 83
■■ Columnas con nulos restantes:
renta_final      2761
miembrosfamilia  4966
menores18        4966
entre18_45       4966
entre46_65       4966
jubilados        4966
tipofamilia      4966
dtype: int64
```

Las columnas:

siguiente_categoria 1987

umbral_siguiente_categoria 1987

gap_a_siguiente_categoria 1987

Los clientes que ya están en la categoría máxima Black (no tienen "siguiente categoría" a la que avanzar, por lo que el umbral y el gap no aplican — nulo lógico, no un dato faltante por error).

CELDA 9: CÓDIGO

```
#Análisis de los datos atípicos, contenido e identificación
cantidad_9999 = (df_datosabadell['antig'] == 9999).sum()
print(f"Cantidad de registros con antig == '9999, posibles datos atípicos': {cantidad_9999}")
```

RESULTADOS:

```
Cantidad de registros con antig == '9999, posibles datos atípicos': 64
```

CELDA 10: CÓDIGO

```
#Se toma la decisión de eliminar los 64 registros con esos valores antig=9999, de acuerdo al
análisis realizado eran clientes que no forman parte del Banco
df_delete = df_datosabadell[df_datosabadell['antig'] == 9999].copy()
print(f"CORRECCIÓN: Registros con antig == 9999 (para eliminar): {len(df_delete)}")
```

RESULTADOS:

```
CORRECCIÓN: Registros con antig == 9999 (para eliminar): 64
```

CELDA 11: CÓDIGO

```
# Para eliminar realmente del DataFrame principal
df_datosabadell = df_datosabadell[df_datosabadell['antig'] != 9999]

print("\nEliminados los registros con valores 9999")
```

RESULTADOS:

Eliminados los registros con valores 9999

CELDA 12: CÓDIGO

```
#Validamos la eliminacion de los datos atipicos y en total queda 9936 clientes
total_clientes=df_datosabadell.id_cliente.count()
print(f"El total de clientes registrados en la BD es : {total_clientes}")
```

RESULTADOS:

El total de clientes registrados en la BD es : 9936

CELDA 13: CÓDIGO

```
#Se construyen las variables que soportan los objetivos 2 y 3

***Grupos de productos**: cuentas (`ind_cuenta*`), tarjetas/segmento (`ind_cv*`) y productos de
inversión/ahorro/protección.
***nivel_categoria***: nivel de vinculación patrimonial del cliente (Bronce → Black), construido a
partir de `totalpasta` (activo total gestionado), que es la variable que mejor separa los códigos
reales de cartera (`tipcart`).
***segmento_edad***: Joven / Adulto / Senior / Jubilado.
***num_prod_inversion***: nº de productos de inversión/ahorro que ya tiene el cliente.
***tiene_inversion***: variable objetivo binaria para el modelo de jóvenes.
# 'gastos_tot' llega como texto con formato moneda (" euro 1,278.64", " euro - ") -> convertir
a numérico
# Limpieza básica
df_datosabadell['edad'] = df_datosabadell['edad'].replace(0, np.nan)

# 'gastos_tot' llega como texto con formato moneda (" euro 1,278.64", " euro - ") -> convertir
a numérico
df_datosabadell['gastos_tot'] = (
    df_datosabadell['gastos_tot'].astype(str)
    .str.replace('\u20ac', '', regex=False)
    .str.replace(',', '', regex=False)
    .str.strip()
    .replace({'-': '0', 'nan': None})
)
df_datosabadell['gastos_tot'] = pd.to_numeric(df_datosabadell['gastos_tot'],
errors='coerce').fillna(0)

df_datosabadell['renta_final'] =
df_datosabadell['renta_final'].fillna(df_datosabadell['renta_final'].median())
df_datosabadell['edad'] = df_datosabadell['edad'].fillna(df_datosabadell['edad'].median())

# Grupos de columnas de producto
cols_cuenta = [c for c in df_datosabadell.columns if c.startswith('ind_cuenta')]
cols_cv = [c for c in df_datosabadell.columns if c.startswith('ind_cv')]
cols_inversion = ['ind_estalinv', 'ind_fi', 'ind_fialtent', 'ind_pp', 'ind_ppassoci', 'ind_ppemp',
'ind_pprest', 'ind_diposit', 'ind_bonsestruc', 'ind_cialp', 'ind_gransel',
'ind_rentvitindiv', 'ind_renttempind', 'ind_renttempcol', 'ind_vrdafix', 'ind_rfifixaval']
cols_proteccion = ['ind_asvidaestgarcol', 'ind_asvidaestulinkc', 'ind_restorvrf']
cols_financiacion = ['ind_credf', 'ind_credv', 'ind_hipfix', 'ind_hipmixt', 'ind_hipoteca', 'ind_hipvar']

df_datosabadell['num_prod_inversion'] = df_datosabadell[cols_inversion].sum(axis=1)
df_datosabadell['tiene_inversion'] = (df_datosabadell['num_prod_inversion'] > 0).astype(int)

# Segmento de edad
bins_edad = [0, 30, 45, 65, 120]
labels_edad = ['Joven (<=30)', 'Adulto (31-45)', 'Senior (46-65)', 'Jubilado (65+)']
df_datosabadell['segmento_edad'] = pd.cut(df_datosabadell['edad'], bins=bins_edad,
labels=labels_edad, include_lowest=True)

# Nivel de categoria patrimonial (5 tiers) segun totalpasta
etiquetas_tier = ['Bronce', 'Plata', 'Oro', 'Platino', 'Black']
df_datosabadell['nivel_categoria'] = pd.qcut(df_datosabadell['totalpasta'].rank(method='first'),
q=5, labels=etiquetas_tier)
```

```
df_datosabadell[['edad', 'segmento_edad', 'totalpasta', 'nivel_categoria', 'num_prod_inversion', 'tiene_inversion']]
```

RESULTADOS:

	edad	segmento_edad	totalpasta	nivel_categoria	num_prod_inversion	tiene_inversion
0	84.0	Jubilado (65+)	52043.01	Black	3	1
1	75.0	Jubilado (65+)	4219.46	Oro	0	0
2	84.0	Jubilado (65+)	55585.45	Black	5	1
3	55.0	Senior (46-65)	5813.22	Platino	0	0
4	55.0	Senior (46-65)	19000.00	Platino	2	1
...	...	...	...	...	...	...
9995	39.0	Adulto (31-45)	2765.22	Oro	0	0
9996	29.0	Joven (<=30)	9126.13	Platino	0	0
9997	55.0	Senior (46-65)	14.11	Bronce	0	0
9998	44.0	Adulto (31-45)	10031.57	Platino	...	...

CELDA 14: CÓDIGO

```
# --- Umbrales de patrimonio por categoria (para calcular el "gap" a la siguiente) ---
umbrales = df_datosabadell.groupby('nivel_categoria',
observed=True)['totalpasta'].min().sort_values()
orden_tiers = list(umbrales.index)
umbral_siguiente = umbrales.shift(-1)

print('Umbral mínimo de totalpasta por categoría:')
print(umbrales)

def siguiente_categoria(cat):
    idx = orden_tiers.index(cat)
    return orden_tiers[idx+1] if idx < len(orden_tiers)-1 else None

df_datosabadell['siguiente_categoria'] =
df_datosabadell['nivel_categoria'].apply(siguiente_categoria)
df_datosabadell['umbral_siguiente_categoria'] =
df_datosabadell['nivel_categoria'].map(umbral_siguiente)
df_datosabadell['gap_a_siguiente_categoria'] = (df_datosabadell['umbral_siguiente_categoria'] -
df_datosabadell['totalpasta']).clip(lower=0)

df_datosabadell[['id_cliente', 'nivel_categoria', 'totalpasta', 'siguiente_categoria',
'umbral_siguiente_categoria', 'gap_a_siguiente_categoria']].sort_values('gap_a_siguiente_categoria').head(10)
```

RESULTADOS:

```
Umbral mínimo de totalpasta por categoría:
nivel_categoria
Bronce      0.00
Plata      175.89
Oro       1014.58
Platino    4996.38
Black     25777.18
Name: totalpasta, dtype: float64
```

	id_cliente	nivel_categoria	totalpasta	siguiente_categoria	umbral_siguiente_categoria	gap_a_siguiente_categoria
7173	7174	Plata	1014.42	Oro	1014.58	0.16
8903	8904	Bronce	175.50	Plata	175.89	0.39
1285	1286	Plata	1014.16	Oro	1014.58	0.42
9107	9108	Bronce	175.12	Plata	175.89	0.77
5578	5579	Bronce	174.87	Plata	175.89	1.02
198	199	Bronce	174.83	Plata	175.89	1.06

8212	8213	Bronce	174.82	Plata	175.89	1.07
4827	4828	Bronce...				

CELDA 15: CÓDIGO

```
#Segmentacion de clientes por tipo de cuenta
# Lista de columnas a seleccionar
columnas_seleccion = [
    'id_cliente',
    'ind_cuentaexpansion',
    'ind_cuentaexpansionnegocios',
    'ind_cuentaexpansionpremium',
    'ind_cuentaexperiencia',
    'ind_cuentaprimera',
    'ind_cuentaproyeccion',
    'ind_cvautonomos',
    'ind_cvdirect',
    'ind_cvhabit',
    'ind_cvjove',
    'ind_cvjunior',
    'ind_cvmass',
    'ind_cvpstige',
    'ind_cvsenior',
    'ind_estalinv',
    'ind_estalvi',
]

# Seleccionar las columnas (syntax correcta)
df_tipocuenta = df_datosabadell[columnas_seleccion].copy()
```

CELDA 16: CÓDIGO

```
# Función para realizar group by por tipo de cuenta y contar cuántas personas tienen ese tipo de
cuenta (sumar cuando el tipo de cuenta sea igual a 1)
def group_by_tipo_cuenta(df_datosabadell, account_columns):

    # Verificar que las columnas existan en el DataFrame
    missing_columns = [col for col in account_columns if col not in df_datosabadell.columns]
    if missing_columns:
        print(f"Advertencia: Las siguientes columnas no existen en el DataFrame: {missing_columns}")
        # Remover columnas faltantes de la lista
        account_columns = [col for col in account_columns if col not in missing_columns]

    # Crear un DataFrame para almacenar los resultados
    results = []

    for account_type in account_columns:
        # Contar cuántas personas tienen esta cuenta (valor = 1)
        count = df_datosabadell[df_datosabadell[account_type] == 1][account_type].count()

        # Calcular porcentaje del total
        total_clients = df_datosabadell['id_cliente'].nunique() # Usar nunique para contar clientes
        percentage = (count / total_clients) * 100 if total_clients > 0 else 0

        results.append({
            'Tipo de Cuenta': account_type,
            'Cantidad': count,
            'Porcentaje': f"{percentage:.2f}%"
        })

    # Crear DataFrame de resultados
    results_df_datosabadell = pd.DataFrame(results)

    # Ordenar por cantidad de personas de mayor a menor
    results_df_datosabadell = results_df_datosabadell.sort_values(by='Cantidad', ascending=False)

    return results_df_datosabadell

# También necesitas definir columnas_cuenta (sin 'id_cliente')
columnas_cuenta = []
```

```

'ind_cuentaexpansion',
'ind_cuentaexpansionnegocios',
'ind_cuentaexpansionpremium',
'ind_cuentaexperiencia',
'ind_cuentaprimera',
'ind_cuentaproyeccion',
'ind_cvautonomos',
'ind_cvdirect',
'ind_cvhabit',
'ind_cvjove',
'ind_cvjunior',
'ind_cvmas',
'ind_cvprestige',
'ind_cvsenior',
'ind_estalinv',
'ind_estalvi',
]

```

CELDA 17: CÓDIGO

```

# Usar la función con df_datosabadell en lugar de df_tipocuenta
# IMPORTANTE: Primero el DataFrame, luego las columnas
resultados = group_by_tipo_cuenta(df_datosabadell, columnas_cuenta)
print(resultados)

```

RESULTADOS:

	Tipo de Cuenta	Cantidad	Porcentaje
0	ind_cuentaexpansion	3472	34.94%
14	ind_estalinv	3337	33.58%
15	ind_estalvi	3061	30.81%
3	ind_cuentaexperiencia	804	8.09%
5	ind_cuentaproyeccion	660	6.64%
9	ind_cvjove	660	6.64%
10	ind_cvjunior	541	5.44%
4	ind_cuentaprimera	541	5.44%
12	ind_cvprestige	355	3.57%
2	ind_cuentaexpansionpremium	228	2.29%
7	ind_cvdirect	138	1.39%
13	ind_cvsenior	80	0.81%
1	ind_cuentaexpansionnegocios	70	0.70%
11	ind_cvmas	35	0.35%
6	ind_cvautonomos	11	0.11%
8	ind_cvhabit	2	0.02%

CELDA 18: CÓDIGO

```

#Se calcula el promedio de antigüedad del cliente, coincide con el POWER BI
promedio_antigüedad = (df_datosabadell['antig'].mean())
print(f"El promedio de antigüedad de los clientes es: {promedio_antigüedad}")

```

RESULTADOS:

```

El promedio de antigüedad de los clientes es: 155.33403784219

```

CELDA 19: CÓDIGO

```

#Se calcula el min de antigüedad del cliente coincide con el POWER BI
minimo_antigüedad = (df_datosabadell['antig'].min())
print(f"El Mínimo de antigüedad de la BD de clientes es de: {minimo_antigüedad}")

```

RESULTADOS:

El Mínimo de antigüedad de la BD de clientes es de: 1

CELDA 20: CÓDIGO

```
# Contar cuántos clientes tienen cada indicador activo
conteo_indicadores = {} # <- DEFINIR EL DICCIONARIO PRIMERO

for col in columnas_seleccion:
    if col != 'id_cliente' and col in df_tipocuenta.columns:
        # Asumiendo que los indicadores son binarios (0/1 o True/False)
        conteo = df_tipocuenta[col].sum() if df_tipocuenta[col].dtype in [int, float, bool] else
        len(df_tipocuenta[df_tipocuenta[col] == True])
        conteo_indicadores[col] = conteo # <- Ahora sí está definido
print(conteo_indicadores) # Mostrar todos los conteos, no solo el último
```

RESULTADOS:

```
{'ind_cuentaexpansion': np.int64(3472), 'ind_cuentaexpansionnegocios': np.int64(70), 'ind_cuentaexpansionpremium': np.int64(228), 'i
```

CELDA 21: CÓDIGO

```
# Crear gráfico (funcionará ahora que conteo_indicadores está definido)
pd.Series(conteo_indicadores).sort_values(ascending=False).head(10).plot(
    kind='bar',
    title='Top 10 de los tipos de cuentas con más clientes',
    figsize=(10, 6)
)
plt.xlabel('Indicador')
plt.ylabel('Cantidad de clientes')
plt.xticks(rotation=45, ha='right')
plt.tight_layout()
plt.show()
```

GRÁFICOS GENERADOS:




Figura 1: Gráfico generado en el análisis

CELDA 22: CÓDIGO

```
plt.figure(figsize=(10, 6))
sns.scatterplot(x='edad', y='totalpasta', data=df_datosabadell, alpha=0.5, color='purple')
plt.title('Relación entre Edad y Patrimonio Total')
plt.xlabel('Edad')
plt.ylabel('Total Pasta (Patrimonio)')
plt.yscale('log') # Opcional si hay valores muy altos concentrados
plt.show()
```


GRÁFICOS GENERADOS:

Figura 2: Gráfico generado en el análisis

CELDA 23: CÓDIGO

```
jovenes = df_datosabadell[df_datosabadell['segmento_edad'] == 'Joven (<=30)'].copy()
print(f'Clientes jóvenes en la muestra menos a 30 años: {len(jovenes)}')
print(jovenes['tiene_inversion'].value_counts(normalize=True).round(3))
```

RESULTADOS:

```
Clientes jóvenes en la muestra menos a 30 años: 1790
tiene_inversion
0    0.797
1    0.203
Name: proportion, dtype: float64
```

CELDA 24: CÓDIGO

```
# Definir data_j antes de usarlo
data_j = jovenes # o jovenes.copy() si quieres una copia

fig = px.histogram(data_j, x='num_prod_inversion', color='tiene_inversion', nbins=25,
barmode='overlay',
                    title='Distribución de productos de inversión en jóvenes',
                    labels={'num_prod_inversion': 'Número de productos de inversión'})

fig.show()
```

GRÁFICOS GENERADOS:

Figura 3: Gráfico Plotly interactivo

Título: Distribución de productos de inversión en jóvenes | Tipo: Plotly | [Ver notebook para versión interactiva](#)

CELDA 25: CÓDIGO

```
# Crear carpeta BD_Actualizada si no existe
bd_actualizada_dir = Path.cwd() / "Output_BD_Actualizada"
bd_actualizada_dir.mkdir(exist_ok=True)

output_file = f"datasabadell_actualizado.xlsx"

# Exportar el DataFrame actualizado
df_datasabadell.to_excel(output_file, index=False)
print(f"\nDataFrame exportado exitosamente: {output_file}")
print(f"Total de registros exportados: {len(df_datasabadell)}")
```

RESULTADOS:

DataFrame exportado exitosamente: datasabadell_actualizado.xlsx
Total de registros exportados: 9936